

Universidad Nacional de Colombia

Facultad de Ingeniería



Ejercicios

Presentado por:

Leal Diaz Layonel Camilo

Jaekle Till

Profesor:

José J. Martínez P.

Asignatura:

Inteligencia Artificial y mini-robots

Bogotá, D.C

5 de marzo de 2026

Ejercicio 1. Redes Neuronales desde Cero (NAND y XOR)

Resumen del Proceso Algorítmico


1. **Modelado Estructural:** Se implementó desde cero una clase en Python (usando únicamente numpy) que representa un perceptrón multicapa. A diferencia de usar librerías de alto nivel, la arquitectura se construyó manualmente definiendo tensores de pesos y sesgos para una capa de entrada (2 neuronas), dos capas ocultas (4 neuronas cada una) y una capa de salida (1 neurona), todas utilizando la función de activación sigmoideal.
2. **Propagación y Aprendizaje:** Se desarrolló el mecanismo de propagación hacia adelante (*forward*) para calcular la salida de la red frente a las tablas de verdad de las compuertas lógicas. Posteriormente, el cálculo del error cuadrático activó el motor de retropropagación (*backpropagation*), aplicando el descenso del gradiente iterativamente sobre miles de épocas para ajustar los pesos sinápticos de forma manual.
3. **Evaluación de Resultados:** La red asimiló la lógica de la compuerta NAND con gran éxito, convergiendo el error a un valor muy cercano a cero (≈ 0.005) y acertando en el 100% de la tabla de verdad. Por el contrario, el experimento demostró empíricamente la dificultad del aprendizaje sobre distribuciones no linealmente separables como la XOR, donde el error se estancó en 0.125, indicando que este problema exige un balanceo más profundo de los hiperparámetros iniciales.

Ejercicio 2. Clasificación de Imágenes (Fashion-MNIST)

Resumen de la Implementación y Análisis

1. Ingeniería de Arquitectura CNN: Se migró el enfoque hacia el aprendizaje profundo utilizando TensorFlow y Keras. Para analizar visualmente el conjunto de datos de ropa (Fashion-MNIST), se diseñó una Red Neuronal Convolucional (CNN). Se integraron capas de convolución (Conv2D) y agrupamiento (MaxPooling2D) estructuradas secuencialmente, lo que permitió que la red extrajera primero patrones geométricos y texturas básicas antes de unirlos lógicamente en capas densas profundas.
2. Optimización del Rendimiento: Para garantizar la estabilidad del entrenamiento, se normalizaron los tensores de píxeles al rango. Además, se incluyó una capa de *Dropout* (30%) que apaga estocásticamente las neuronas y un sistema de *EarlyStopping*, previniendo el sobreajuste (*overfitting*) en las 15 épocas planteadas.
3. Análisis de Métricas: El modelo alcanzó una exactitud (*accuracy*) en el conjunto de pruebas aproximada del 91%. Al observar la matriz de confusión, se comprobó que el algoritmo es muy robusto para prendas definidas como pantalones o sandalias (>98% de precisión), mientras que sufre pequeñas confusiones morfológicas naturales entre camisas, camisetas y suéteres.

Output:



precision recall f1-score support

T-shirt/top	0.87	0.85	0.86	1000
Trouser	0.98	0.98	0.98	1000
Pullover	0.86	0.85	0.86	1000
Dress	0.88	0.94	0.91	1000
Coat	0.85	0.86	0.86	1000
Sandal	0.98	0.98	0.98	1000
Shirt	0.76	0.72	0.74	1000
Sneaker	0.96	0.95	0.96	1000
Bag	0.98	0.98	0.98	1000
Ankle boot	0.95	0.97	0.96	1000
accuracy	0.91			10000
macro avg	0.91	0.91	0.91	10000
weighted avg	0.91	0.91	0.91	10000

Ejercicio 3. Predicción con Datos Tabulares (Dataset Titanic)

Resumen del Procesamiento Tabular

1. **Preprocesamiento Estocástico y Estructural:** Se seleccionó el conjunto de datos de Kaggle sobre la supervivencia en el Titanic. Se realizó una limpieza de la información imputando las edades faltantes mediante medianas estadísticas y binarizando el género. Las características numéricas finales (Pclass, Sex, Age, SibSp, Parch, Fare) fueron estandarizadas con *StandardScaler* para acelerar la convergencia del entrenamiento.
2. **Desarrollo del Perceptrón Multicapa (MLP):** Se modeló una arquitectura densa en Keras con dos capas ocultas (32 y 16 neuronas) empleando la activación lineal rectificada (ReLU). El terminal de salida se comprimió a una única neurona con activación sigmoideal, diseñada puramente para emitir la probabilidad de supervivencia frente al naufragio mediante entropía cruzada binaria.
3. **Conclusión de la Predicción:**
Se logró un sistema predictivo capaz de encontrar relaciones no lineales entre factores demográficos y socioeconómicos, y la probabilidad de supervivencia. El algoritmo obtuvo un rendimiento aceptable del 79% de exactitud sobre el segmento de pruebas ciego, logrando abstraer características biológicas complejas de una tragedia real en patrones computacionales de peso y sesgo.

